



15 MIN • TEAMPRÄSENTATION

ClaimGuard

Evidenzbasierte Prüfung akademischer Integrität

Von Aussagen im PDF zur Referenzprüfung und Quellenbewertung

Nils Wagner • Nick Wenzel

MWI Deep Learning Capstone • 3. Juli 2026

Warum die Prüfung akademischer Integrität wichtig ist

Eine Quelle kann echt sein ...

**... und trotzdem die
zitierte Aussage nicht
stützen.**

Manuelle Prüfung ist langsam; naive
Automatisierung erzeugt falsche
Verdächtigungen.

VORPRÜFUNG, KEIN URTEIL

- **Umfang** Lange Berichte enthalten viele überprüfbare Aussagen.
- **Feinheit** Existenz, Relevanz und faktische Stützung sind verschiedene Fragen.
- **Risiko** Fehllarme können Studierenden und Forschenden unfair schaden.
- **Bedarf** Prüfende brauchen nachvollziehbare Evidenz statt einer Blackbox-Zahl.

**Ziel: Auffällige Passagen schneller prüfen und
verständlich begründen.**

Drei Prüfungen — ein nachvollziehbarer Bericht

01

Benötigt das eine Quelle?

Aussagetyp, Abschnitt,
Zitiermarker, Schweregrad

02

Existiert die Quelle?

IEEE-Parsing plus
wissenschaftliche Metadaten-
APIs

03

Stützt die Quelle die Aussage?

Evidenzsuche plus fünfstufige
Verifikation

Ausgabe: lesbares Markdown + vollständige JSON-Provenienz für Evaluation und Audit

Pipeline-Architektur

**AUDIT-SPUR**

Evidenz • Konfidenz • Modell-ID • Latenz • Tokenverbrauch • Antwort-/Anfrage-IDs

Offline zuerst**Regelbasierter Fallback**

Netzwerkfunktionen nur optional

Ein Schema**Vergleichbare Backends**

Fünf Unterstützungslabels

Mensch prüft**Endgültige Entscheidung**

Kein automatischer Täuschungsvorwurf

Technische Entscheidungen und Zielkonflikte

EVIDENZSUCHE

all-MiniLM-L6-v2

Semantischer Abgleich; Kosinus-Fallback unter Windows

METADATEN

CrossRef • OpenAlex • S2

Abdeckung von DOI, Titel, Autoren und Open-Access-Status

LOKAL

Ollama / qwen3:1.7b

Privat und offline; auf diesem Rechner langsamer

FRONTIER

OpenAI gpt-5.4-mini

Schnelle strukturierte Ausgabe; kostenpflichtig und extern

FINE-TUNING

SciFact LoRA

Günstige lokale Inferenz; Taxonomie mit drei Labels

Designprinzip: kontrollierte Degradation — API- oder Embedding-Fehler stoppen den Bericht nicht.

Demo mit unserem echten RQ5-Bericht

POWERSHELL

```
python run_claimguard.py `
  --input Reports/NW2_RQ5_Report.pdf --verifier openai `
  --output outputs/rq5_openai.json --markdown-output
  outputs/rq5_openai.md
```

137

Sätze

65faktische
Aussagen**21**Quellenhin
weise

ECHTE AUSSAGE AUS SATZ 11 (ÜBERSETZT)

**„RAG verbindet ein Sprachmodell mit
externem Wissen, ohne Modellgewichte zu
verändern.“**

Erkannte Quellen: [1, 3] • Beste Evidenz gespeichert

OPENAI

unzureichende**Evidenz**

1.889 s • 506 tokens


OLLAMA

gestützt

40,902 s • lokal

Kernaussage: Die Evidenz ist sichtbar — Unterschiede werden prüfbar statt verborgen.

Zentrale Ergebnisse: kontrollierte Tests vs. echte Berichte

**1.000****Genauigkeit des IEEE-Parsers**

Fünf Testfälle mit vollständigen Feldern

0.267**F1 für Quellenbedarf**

50 manuell annotierte RQ-Sätze

0.353**SciFact-Validierung: Macro-F1**

450 Validierungspaare

Hauptergebnis: Synthetische Benchmarks überschätzen den Transfer einfacher Regeln auf echte PDFs.

Modellvergleich: Geschwindigkeit, Kontrolle und Taxonomie

Backend	Beobachtetes Ergebnis	Latenz	Geeigneter Einsatz	Einschränkung
Heuristik	0.900 F1*	~0 ms	Transparente Baseline	Beruhrt auf Oberflächenmustern
LoRA	0.172 F1*	9.3 ms	Günstige lokale Inferenz	SciFact hat 3 statt 5 Labels
Ollama	gestützt†	40.9 s	Private lokale Prüfung	Langsam; eine diagnostische Aussage
OpenAI	unzureichend†	1.89 s	Strukturierte Frontier-Prüfung	Kostenpflichtig/extern; eine diagnostische Aussage

* Gold-Benchmark mit 30 Fällen † dieselbe echte RQ5-Aussage; nur diagnostisch — kein Genauigkeitsvergleich

Was funktioniert — und wo es scheitert

FUNKTIONIERT GUT

- Durchgängiger Ablauf von PDF zu Markdown/JSON
- Nachvollziehbare Evidenz und Backend-Metadaten
- Robustes IEEE-Parsing für Bericht 5
- Offline-Fallback und echter CUDA-LoRA-Pfad

EINSCHRÄNKUNGEN

- PDF-Extraktion erzeugt Abstands- und Überschriftenfehler
- Erkennung echter Aussagen generalisiert schwach
- Metadaten-APIs können ausfallen oder drosseln
- Binoculars' kalibriertes 14B-Paar übersteigt 8 GB VRAM

Ethische Grenze: Ein Hinweis priorisiert menschliche Prüfung; er beweist weder Täuschung noch KI-Autorschaft.

ClaimGuard macht Integritätsprüfungen nachvollziehbar.

01

Pipeline

Aussagen, Referenzen, Evidenz und Bewertungen in einem Ablauf.

02

Evidenz

Evaluation mit echten Berichten zeigt, wo synthetische Werte täuschen.

03

Verantwortung

Automatisierung lenkt menschliche Aufmerksamkeit — sie ersetzt kein Urteil.

Nächster Schritt: doppelt annotierte Echtdaten erweitern und den vollständigen OpenAI/Ollama-Benchmark ausführen.



Fragen & Diskussion

5 Minuten

Architektur • Evaluation • Modell-Zielkonflikte • Ethik