



15 MIN • TEAMPRÄSENTATION

ClaimGuard

Evidenzbasierte Prüfung akademischer Integrität

Von Aussagen im PDF zur Referenzprüfung und Quellenbewertung

Nils Wagner • Nick Wenzel

MWI Deep Learning Capstone • 3. Juli 2026

Warum die Prüfung akademischer Integrität wichtig ist

Eine Quelle kann echt sein ...

**... und trotzdem die
zitierte Aussage nicht
stützen.**

Manuelle Prüfung ist langsam; naive
Automatisierung erzeugt falsche
Verdächtigungen.

VORPRÜFUNG, KEIN URTEIL

- Umfang Lange Berichte enthalten viele überprüfbare Aussagen.
- Feinheit Existenz, Relevanz und faktische Stützung sind verschiedene Fragen.
- Risiko Fehllarme können Studierenden und Forschenden unfair schaden.
- Bedarf Prüfende brauchen nachvollziehbare Evidenz statt einer Blackbox-Zahl.

**Ziel: Auffällige Passagen schneller prüfen und
verständlich begründen.**

Drei Prüfungen — ein nachvollziehbarer Bericht

01

Benötigt das eine Quelle?

Aussagetyp, Abschnitt,
Zitiermarker, Schweregrad

02

Existiert die Quelle?

IEEE-Parsing plus
wissenschaftliche Metadaten-
APIs

03

Stützt die Quelle die Aussage?

Evidenzsuche plus fünfstufige
Verifikation

Ausgabe: lesbares Markdown + vollständige JSON-Provenienz für Evaluation und Audit

Pipeline-Architektur

**AUDIT-SPUR**

Evidenz • Konfidenz • Modell-ID • Latenz • Tokenverbrauch • Antwort-/Anfrage-IDs

Offline zuerst**Regelbasierter Fallback**

Netzwerkfunktionen nur optional

Ein Schema**Vergleichbare Backends**

Fünf Unterstüztungslabels

Mensch prüft**Endgültige Entscheidung**

Kein automatischer Täuschungsvorwurf

Modulabdeckung: erfüllt und offen

KERN 1–3	Abgeschlossen	Claims/Zitate, Bibliografie und RAG-Verifikation; verpflichtend und evaluiert.	ERFÜLLT
MODUL 5	LoRA abgeschlossen	SciFact-Adapter trainiert, gespeichert und labelgleich sowie im Transfer verglichen.	ERFÜLLT
MODUL 4	Über Fast-DetectGPT erfüllt	Offizielle API auf N=30 evaluiert; Binoculars' kalibriertes 14B-Paar übersteigt 8 GB VRAM.	ERFÜLLT
MODUL 6	Nur Vergleichsgerüst	Import- und Evaluationscode existiert, aber keine scite-/SemanticCite-Vorhersagen lagen vor.	OFFEN

Als erfüllt ausgewiesen: Kernmodule 1–3 + optionale Module 4 und 5 • Modul 6 bleibt Future Work.

Technische Entscheidungen und Zielkonflikte

EVIDENZSUCHE

all-MiniLM-L6-v2

Semantischer Abgleich; Kosinus-Fallback unter Windows

METADATEN

CrossRef • OpenAlex • S2

Abdeckung von DOI, Titel, Autoren und Open-Access-Status

LOKAL

Ollama / qwen3:1.7b

Privat und offline; auf diesem Rechner langsamer

FRONTIER

OpenAI gpt-5.4-mini

Schnelle strukturierte Ausgabe; kostenpflichtig und extern

FINE-TUNING

SciFact LoRA

Günstige lokale Inferenz; Taxonomie mit drei Labels

Designprinzip: kontrollierte Degradation — API- oder Embedding-Fehler stoppen den Bericht nicht.

Analyse konfigurieren

Prüfmethode ?

Heuristik · lokal & schnell

☒ Wissenschaftliche APIs
verwenden ?

☒ KI-Text-Indikator ?

ClaimGuard ist ein Triage-Werkzeug.
Jede Markierung braucht menschliche
Prüfung.



Akademische Aussagen, Zitationen und Quellenbelege nachvollziehbar prüfen.

1 · Dokument auswählen

☐ Beispiel ☒ Datei hochladen ☐ Text einfügen

PDF- oder TXT-Datei




NW2_RQ5_Report.pdf
445.5KB



Dokument analysieren

Wähle ein Dokument aus und starte die Analyse. Das problematische Beispiel eignet sich für die erste Demo.

Zentrale Ergebnisse: kontrollierte Tests vs. echte Berichte

**1.000****Referenz-Parse-Rate**

30 echte + kontrollierte Fälle

0.267**F1 für Quellenbedarf**

50 manuell annotierte RQ-Sätze

0.924**Fast-DetectGPT AUROC**

15 menschliche + 15 GPT-4-Passagen

Hauptergebnis: Synthetische Benchmarks überschätzen den Transfer einfacher Regeln auf echte PDFs.

Modellvergleich: Geschwindigkeit, Kontrolle und Taxonomie

Backend	Beobachtetes Ergebnis	Latenz	Geeigneter Einsatz	Einschränkung
Heuristik	0.868 Macro-F1	~0 ms	Transparente Baseline	Beruhrt auf Oberflächenmustern
LoRA	0.172 Macro-F1	6 ms	Günstige lokale Inferenz	SciFact hat 3 statt 5 Labels
Ollama	0.728 Macro-F1	2.74 s	Private lokale Prüfung	Überschätzt vollständige Stützung
OpenAI	0.518 Macro-F1	1.42 s	Strukturierte Frontier-Prüfung	Kostenpflichtig/extern; Kosten nicht erfasst

Dieselben 30 Gold-Fälle und identische Evidenz • 3 Enthaltungen ohne Evidenz

Was funktioniert — und wo es scheitert

FUNKTIONIERT GUT

- Durchgängiger Ablauf von PDF zu Markdown/JSON
- Nachvollziehbare Evidenz und Backend-Metadaten
- Robustes IEEE-Parsing für Bericht 5
- LoRA und Fast-DetectGPT reproduzierbar evaluiert

EINSCHRÄNKUNGEN

- PDF-Extraktion erzeugt Abstands- und Überschriftenfehler
- Erkennung echter Aussagen generalisiert schwach
- Metadaten-APIs können ausfallen oder drosseln
- Fast-DetectGPT übersah 7/15 generierte Passagen

Ethische Grenze: Ein Hinweis priorisiert menschliche Prüfung; er beweist weder Täuschung noch KI-Autorschaft.

ClaimGuard macht Integritätsprüfungen nachvollziehbar.

01

Pipeline

Aussagen, Referenzen, Evidenz und Bewertungen in einem Ablauf.

02

Evidenz

Evaluation mit echten Berichten zeigt, wo synthetische Werte täuschen.

03

Verantwortung

Automatisierung lenkt menschliche Aufmerksamkeit — sie ersetzt kein Urteil.

Nächster Schritt: Doppelannotation, externer Tool-Benchmark und consentierte Zitiermusterstudie.



Fragen & Diskussion

5 Minuten

Architektur • Evaluation • Modell-Zielkonflikte • Ethik